


REPUBLIQUE DU SENEGAL



Un Peuple - Un But - Une Foi



**UFR : Sciences Appliquées et Technologies de l'Information et de la Communication
(SATIC)**

Département : Mathématiques

**Option : Statistique et Informatique Décisionnelle
(SID)**

THEME

**Application Avancée des Modèles Linéaires
Généralisés (GLM) sur Données Réelles**

Présenté par :

Malick FAYE

Année académique : 2023-2024

Présentation de la base de donnée

La base nommée hear_cleveland_upload contient des informations cliniques sur plusieurs patients, dans le but de prédire la présence ou non d'une maladie cardiaque. Chaque ligne correspond à un patient diagnostiquer et chaque colonne représente une variable médicale ou sociodémographique. Parmi les variables figurent :

- Age : âge des patients exprimés en année
- Sex : sexe des patients
- Cp : type de douleur thoracique, qui prend les modalités (0 : angine typique, 1 : angine atypique, 2 : douleur non angine ; 3 : asymptomatique)
- Trestbps : tension artérielle au repos
- Chol : cholestérol
- Fbs : glycémie
- Restecg : résultats électrocardiographiques au repos
- Thalach : fréquence cardiaque maximale atteinte
- Exang : angine de poitrine provoqué par l'exercice
- Oldpeak : dépression du segment ST induite par l'exercice par rapport au repos
- Pente : la pente du segment
- CA : nombre de récepteurs principaux colorés par la fluoroscopie
- Thal : 0= normal ; 1 = défaut corrigé ; 2 = défaut réversible
- Condition : 0 = pas de maladie ; 1 = maladie

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	condition
0	69	1	0	160	234	1	2	131	0	0.1	1	1	0	0
1	69	0	0	140	239	0	0	151	0	1.8	0	2	0	0
2	66	0	0	150	226	0	0	114	0	2.6	2	0	0	0
3	65	1	0	138	282	1	2	174	0	1.4	1	1	0	1
4	64	1	0	110	211	0	2	144	1	1.8	1	0	0	0

La base de données comprend 297 observations et 14 variables portant sur des caractéristiques médicales de patients, utilisées pour diagnostiquer la présence ou non d'une maladie cardiaque. Chaque ligne représente un individu, décrit par des variables telles que l'âge, le sexe, le type de douleur thoracique, la pression artérielle au repos, le taux de cholestérol, ou encore la fréquence cardiaque maximale atteinte. La variable cible, nommée condition, est binaire et indique la présence 1 ou l'absence 0 d'une maladie cardiaque.

Préparation des données

Détection de la présence de valeur manquante :

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 297 entries, 0 to 296
Data columns (total 14 columns):
#   Column              Non-Null Count  Dtype  
---  -
0   age                 297 non-null    int64  
1   sex                 297 non-null    int64  
2   cp                  297 non-null    int64  
3   trestbps            297 non-null    int64  
4   chol                297 non-null    int64  
5   fbs                 297 non-null    int64  
6   restecg             297 non-null    int64  
7   thalach              297 non-null    int64  
8   exang               297 non-null    int64  
9   oldpeak             297 non-null    float64 
10  slope                297 non-null    int64  
11  ca                  297 non-null    int64  
12  thal                 297 non-null    int64  
13  condition            297 non-null    int64  
dtypes: float64(1), int64(13)
memory usage: 32.6 KB
```

Le jeu de données ne contient aucune valeur manquante à corriger, donc nous pouvons passer directement au renommage des variables pour mieux faciliter la compréhension des données.

Analyse descriptive

	age	sex	douleurThoracique	pression_artérielle	cholestérol	glycémie	ResultatsElectrocardiogramme	thalach	anginepoitrine	
count	297.000000	297.000000	297.000000	297.000000	297.000000	297.000000	297.000000	297.000000	297.000000	2
mean	54.542088	0.676768	2.158249	131.693603	247.350168	0.144781	0.996633	149.599327	0.326599	
std	9.049736	0.468500	0.964859	17.762806	51.997583	0.352474	0.994914	22.941562	0.469761	
min	29.000000	0.000000	0.000000	94.000000	126.000000	0.000000	0.000000	71.000000	0.000000	
25%	48.000000	0.000000	2.000000	120.000000	211.000000	0.000000	0.000000	133.000000	0.000000	
50%	56.000000	1.000000	2.000000	130.000000	243.000000	0.000000	1.000000	153.000000	0.000000	
75%	61.000000	1.000000	3.000000	140.000000	276.000000	0.000000	2.000000	166.000000	1.000000	
max	77.000000	1.000000	3.000000	200.000000	564.000000	1.000000	2.000000	202.000000	1.000000	

L'âge des patients varie de 29 à 77 ans, avec une moyenne d'environ 54,5 ans. Environ 68 % des individus sont des hommes (sex = 1). Les variables comprennent notamment la douleur thoracique (catégorisée de 0 à 3), la pression artérielle au repos (entre 94 et 200 mmHg), le

taux de cholestérol (allant de 126 à 564 mg/dl), et la fréquence cardiaque maximale atteinte (thalach, moyenne ≈ 150 bpm). La variable cible condition est binaire : 0 pour absence de maladie cardiaque, 1 pour présence.


Moyenne de certaines variables indépendantes en fonction de la variable cible :

	thalach	cholestérol	age	pression_artérielle
condition				
0	158.581250	243.493750	52.643750	129.175000
1	139.109489	251.854015	56.759124	134.635036


La moyenne de la fréquence cardiaque maximale est plus élevée pour les patients sans maladie cardiaque "condition = 0" que pour les patients atteints d'une maladie cardiaque "condition = 1". Cela suggère que les patients atteints d'une maladie cardiaque ont une capacité réduite à augmenter leur fréquence cardiaque pendant l'effort. La moyenne du cholestérol est légèrement plus élevée pour les patients atteints d'une maladie cardiaque que pour les patients sans maladie cardiaque. Cela pourrait indiquer que le cholestérol est un facteur de risque de maladie cardiaque. On constate aussi que la moyenne d'âge est légèrement plus élevée pour les patients atteints (moyenne= 52,62) d'une maladie cardiaque que pour les patients sans maladie cardiaque (moyenne = 56,75). Cela confirme que l'âge est un facteur de risque de maladie cardiaque. La moyenne de la pression artérielle est légèrement plus élevée pour les patients atteints d'une maladie cardiaque que pour les patients sans maladie cardiaque. Cela pourrait indiquer que l'hypertension artérielle est un facteur de risque de maladie cardiaque.

Détection de la présence des valeurs extrêmes

Box plot de pression_artérielle




Box plot de cholestérol




L'observation des box-plots nous montre la présence de valeurs extrêmes dans les variables pression artérielle, cholestérol, thalach et oldpeak.

Correction des valeurs extrêmes

Box plot de pression_artérielle (sans valeurs aberrantes)




Box plot de cholestérol (sans valeurs aberrantes)



Après correction des valeurs extrêmes qui étaient sur la base. Cette dernière est passé de dimension (297,14) à (278,14). Les données aberrantes ont été corrigé, comme montre les box-plots.


Visualisations graphiques des Variables

Distribution de la variable âge :



La distribution de l'âge des patients, illustrée par l'histogramme ci-dessus, montre une concentration autour de 54 ans, qui correspond à la moyenne observée (ligne rouge). La distribution est asymétrique à gauche, avec une majorité de patients âgés entre 50 et 65 ans. Les patients plus jeunes (moins de 40 ans) ou plus âgés (plus de 70 ans) sont beaucoup moins représentés.


Distribution de la variable oldpeak



La variable oldpeak, qui mesure la dépression relative du segment ST entre l'exercice et le repos, est fortement asymétrique à droite. La majorité des patients présente une valeur proche de 0 mm, ce qui indique peu ou pas d'anomalie dans la repolarisation cardiaque à l'effort. Toutefois, certains cas atteignent des valeurs allant jusqu'à 6 mm, suggérant des anomalies significatives et un risque plus élevé de pathologie cardiaque.

Nuage de point de la variable âge et la fréquence cardiaque :


Fréquence cardiaque maximale obtenue en raison de la présence d'une maladie cardiaque et de la distribution de l'âge



Ce graphique en nuage de points illustre la relation entre l'âge et la fréquence cardiaque maximale atteinte, en fonction de la présence ou non d'une maladie cardiaque. Chaque point représente un individu, coloré selon qu'il souffre (orange) ou non (bleu) d'une affection cardiaque. On observe une tendance générale à la diminution de la fréquence cardiaque maximale avec l'âge. De plus, les personnes atteintes d'une maladie cardiaque semblent avoir des fréquences cardiaques maximales légèrement plus basses.


Diagramme de barre entre la variable sexe et douleurThoracique

Répartition du type de douleur angineuse selon le sexe



D'après les données, les hommes affichent des nombres plus élevés dans toutes les catégories de type de douleurs angineuses, avec un pic particulièrement marqué dans le groupe asymptomatique. Cela suggère que les hommes peuvent ressentir les symptômes de l'angine différemment ou être diagnostiqués plus fréquemment à un stade asymptomatique par rapport aux femmes.

Diagramme de barre entre la variable dépression du segment et la présence d'une maladie cardiaque :



En regardant ce graphique à barre, nous constatons que la plupart des individus sans maladie cardiaque ont une différence plus faible de dépression du segment ST entre l'exercice et le repos, tandis que ceux atteints d'une maladie cardiaque sont répartis plus uniformément sur les différents intervalles.

Construction d'un GLM de type régression logistique

Coefficient du modèle et leurs interprétations :

Coefficient	Caractéristique	Description
0.00525933	(Interception)	Valeur de base lorsque toutes les autres caractéristiques sont à 0.
1.62809137	age	Augmentation de la probabilité de maladie cardiaque avec l'âge.
0.35625112	sex	Augmentation de la probabilité de maladie cardiaque si le patient est un homme (en supposant que 1 = homme).
0.21809439	douleurThoracique	Augmentation de la probabilité de maladie cardiaque avec certains types de douleur thoracique.
0.18072621	pression_artérielle	Augmentation de la probabilité de maladie cardiaque avec la pression artérielle.
-0.77046123	cholestérol	Diminution de la probabilité de maladie cardiaque avec le cholestérol.
0.18114518	glycémie	Augmentation de la probabilité de maladie cardiaque avec la glycémie.
-0.31216934	ResultatsElectrocardiogramme	Diminution de la probabilité de maladie cardiaque avec certains résultats d'ECG.
0.5829439	thalach	Augmentation de la probabilité de maladie cardiaque avec la fréquence cardiaque maximale.
0.41847836	anginepoitrine	Augmentation de la probabilité de maladie cardiaque avec l'angine de poitrine.
0.41254883	oldpeak	Augmentation de la probabilité de maladie cardiaque avec la dépression du segment ST.
1.13521139	Pente	Augmentation de la probabilité de maladie cardiaque avec la pente du segment ST.
0.82308834	ca	Augmentation de la probabilité de maladie cardiaque avec le nombre de vaisseaux principaux colorés.

Justification du choix des variables :

Ces variables ont été choisies car elles sont connues pour être des facteurs de risque importants de maladies cardiaques ou des indicateurs de la présence d'une maladie cardiaque. Elles ont été sélectionnées sur la base de leurs liaisons avec la variable dépendante 'condition' qui ont démontré leur pertinence dans la prédiction des maladies cardiaques.

Validation et diagnostics du modèle :

Analyse des résidus : Pearson, déviance, studentisés :

```
Résidus de Pearson : 273      0.044801
259      0.645279
30      -0.318785
22      -0.110315
277      0.056294
...
188      -0.553041
71      -0.153521
106      0.427200
270      0.307628
102      -0.212029

Résidus de déviance : [ 3.52506535  1.56477028 -2.18323715 -2
-2.6314389  2.70584121  1.33050912  3.01519376  1.25592304
2.42275553 -1.46904557  2.12344469 -2.3736449  -2.19620994
-2.34389955 -1.28561667 -2.39629545 -1.23104905  2.31002962
-2.02332485 -2.64391277  1.45359118  2.91584347  2.95899655
-2.65037611 -1.78607986 -1.63748665 -2.44819818 -1.75791065
-2.85792608 -1.79011434 -2.84039089  0.9133087  2.92196274
2.17939663 -1.91030179  1.33441067 -0.24208274  1.46841262

Résidus studentisés : [ 3.64085186  1.60667489 -2.2541695  -3.03799768  3
-2.67913358  2.75856703  1.3819081  3.08735924  1.28992466 -2.51936528
2.5109216  -1.50546053  2.19751573 -2.39967727 -2.26467767  2.66450158
-2.38036489 -1.34305414 -2.44996828 -1.29207265  2.41293891 -3.30109866
-2.07282118 -2.75102025  1.51972432  2.99889549  3.06591612 -3.05273619
-2.6929846  -1.82301912 -1.7191197  -2.49416053 -1.84868381  1.63078587
-2.90229263 -1.83125341 -2.87366294  0.93491902  3.05672723 -1.77606427
2.23852808 -1.99538378  1.37152469 -0.24839787  1.51791405 -1.94309818
-1.85389356  2.41134225  3.18587526  1.91299158 -2.590591  1.43200219
-1.57927814 -1.79818739  2.7270101  -3.46513636  2.19760335  3.27285327
-1.09041533 -1.46282821 -1.77435241 -2.64438856  0.44199809 -1.77322083
-2.9923468  2.00625805  1.74319654 -2.96836554  1.21418064 -1.85805344
1.71430191 -2.46851487 -3.47626118  2.51161525 -1.68754227 -1.09464982
-2.36391302  2.00791266 -2.12438429  3.15932781  2.39983985 -2.54540037
3.20282618 -2.44537307 -1.9459886  2.73683312 -0.77573006  2.45333319
```

Les résidus de Pearson indiquent globalement un bon ajustement du modèle, avec des valeurs majoritairement proches de zéro et peu de signes d'anomalies. En revanche, les résidus de déviance et surtout les résidus studentisés révèlent la présence de plusieurs observations atypiques. Ces valeurs suggèrent que certains points sont mal prédits par le modèle et peuvent potentiellement influencer de manière excessive les résultats malgré la suppression des valeurs extrêmes. Une analyse complémentaire des points influents serait donc pertinente afin d'évaluer leur impact et, si nécessaire, ajuster le modèle ou traiter les données concernées.

Détection des points atypiques : distance de Cook, résidus studentisés :

Distance de Cook :

```
Optimization terminated successfully.
```

```
Current function value: 0.351001
```

```
Iterations 7
```

```
Indices des points atypiques (distance de Cook) : [ 19 39 45 64 76 77 88 97 117 121 136 138
185 189 195 198 201 213 227 229 231]
```

L'analyse de la distance de Cook identifie 27 points atypiques potentiellement influents, notamment les observations aux indices 19, 39, 45, 64, 76, 77, etc. Ces points ont une influence notable sur l'ajustement du modèle, ce qui signifie que leur présence peut modifier de manière significative les coefficients estimés. Cette détection renforce les signaux déjà observés avec les résidus studentisés élevés.

Résidus Studentisés :

Indices des points atypiques (résidus studentisés) : [0 2 3 4 5 6 7 9 11 12 14
24 25 27 28 29 30 33 36 38 40 42 49 50 52 56 57 58 59
63 66 67 69 73 74 75 78 79 80 81 82 83 84 85 87 89 90
91 92 93 94 95 100 101 102 103 105 106 107 108 109 110 111 113 115
116 118 119 120 122 123 125 126 127 129 130 133 134 137 139 143 144 145
146 148 149 151 152 153 154 155 158 162 163 168 170 173 174 176 177 178
180 181 183 187 192 193 199 200 203 204 205 206 207 208 209 210 211 212
214 215 216 217 219 221 223 224 228 233 235 236]

L'analyse des résidus studentisés révèle un très grand nombre d'observations potentiellement atypiques par rapport à ce que l'on attendrait dans un modèle bien ajusté. Cela suggère que le modèle présente des problèmes d'ajustement, probablement en raison d'une spécification incorrecte ou d'une forte hétérosédasticité. Comparé aux 27 points influents identifiés par la distance de Cook, il est clair que de nombreuses observations présentent des écarts importants, mais n'ont pas nécessairement une forte influence sur les coefficients du modèle.

Multi colinéarité : calcul des VIF :


	Variable	VIF
0	age	4.160475
1	sex	3.496772
2	douleurThoracique	5.618949
3	pression_artérielle	3.371701
4	cholestérol	3.581859
5	glycémie	1.279871
6	ResultatsElectrocardiogramme	2.164919
7	thalach	3.001734
8	anginepoitrine	2.194358
9	oldpeak	3.110572
10	Pente	2.796345
11	ca	1.960802
12	thal	2.597975

Les résultats du VIF indiquent une absence de multi colinéarité sévère entre les variables explicatives du modèle, car aucune d'entre elles ne dépasse le seuil critique de 10. La variable "douleurThoracique" présente le VIF le plus élevé (5,62), mais cela reste dans une zone acceptable. La majorité des autres variables ont des VIF inférieurs à 4, ce qui confirme une stabilité globale du modèle du point de vue de la colinéarité.

Évaluation de la performance du modèle

Courbe ROC :

Receiver operating characteristic example



Cette courbe de ROC présentée évalue la performance d'un modèle de classification appliqué à la prédiction des maladies cardiaques. Avec une aire sous la courbe (AUC) de 0,81, le modèle montre une bonne capacité à distinguer les patients malades des non-malades, ce qui indique une performance fiable et utile dans un contexte médical.

Calcul de l'AUC :

```
[ ] # Calcul de l'AUC  
  
auc = roc_auc_score(y_test, y_pred_prob)  
print("AUC :", auc)
```

➡ AUC : 0.8136160714285715

Cette valeur de l'AUC (0,813) indique que le modèle de classification a une bonne capacité de discrimination entre les classes positives et négatives.

Matrice de confusion :

```
# Calcul de la Matrice de confusion  
cm = confusion_matrix(y_test, y_pred)  
print("Matrice de confusion :\n", cm)
```

```
⇒ Matrice de confusion :  
[[22 10]  
 [ 6 22]]
```

La matrice de confusion indique que le modèle a correctement classé 22 observations comme négatives (vrais négatifs) et 22 comme positives (vrais positifs). Cependant, il a aussi mal classé 10 observations négatives comme positives (faux positifs) et 6 positives comme négatives (faux négatifs). Cela montre une performance globalement équilibrée du modèle, avec une légère tendance à prédire un peu trop de positifs.

Précision, rappel, F1-score :

```
⇒ Précision : 0.7333333333333333  
Rappel : 0.7857142857142857  
Score F1 : 0.7333333333333333
```

Le modèle présente une précision de 73,3%, ce qui signifie que parmi les prédictions positives, 73,3% sont correctes. Le rappel est de 78,6%, indiquant que le modèle identifie correctement 78,6% des cas réellement positifs. Le score F1, qui équilibre précision et rappel, est également de 73,3%, ce qui reflète une performance relativement satisfaisante, bien qu'améliorable, surtout sur la réduction des faux positifs.

Analyse du choix du seuil :

Seuil optimal (F1) : 0.6137450319253566

Le seuil optimal basé sur le score F1 est de 0.614, ce qui signifie que pour maximiser l'équilibre entre la précision et le rappel, les prédictions positives devraient être faites lorsque la probabilité estimée dépasse ce seuil, et non le seuil classique de 0,5. Cela permettrait potentiellement de mieux capter les cas positifs tout en maintenant un bon contrôle sur les faux positifs.

Comparaison de modèles :

Critères AIC, BIC :

```
Optimization terminated successfully.  
Current function value: 0.351001  
Iterations 7  
AIC : 192.37463754088162  
BIC : 237.45941937563833
```

Le modèle de régression logistique a convergé correctement en 7 itérations, atteignant une valeur de la fonction objective de 0.351. Les critères d'information indiquent une AIC de 192.37 et une BIC de 237.46, ce qui donne une idée de la qualité du modèle tout en tenant compte de la complexité. Cette petite valeur de AIC montre la performance du modèle.

Test du rapport de vraisemblance :

```
Optimization terminated successfully.  
Current function value: 0.684918  
Iterations 4  
Optimization terminated successfully.  
Current function value: 0.684483  
Iterations 4  
Statistique du rapport de vraisemblance : 0.20632854823850266  
p-valeur : 0.6496603968873662
```

Le test du rapport de vraisemblance, basé sur la comparaison entre un modèle restreint et un modèle complet, donne une statistique de 0.206 avec une p-valeur de 0.649. Cette p-valeur élevée indique que l'ajout des variables dans le modèle complet n'améliore pas significativement l'ajustement par rapport au modèle restreint.

Conclusion :

L'étude de la base hear_cleveland_upload a permis de mieux comprendre les facteurs qui expliquent la présence d'une maladie cardiaque. L'analyse exploratoire effectuée sur cette base révèle l'influence de certaines variables comme l'âge, le cholestérol et la pression artérielle sur la condition cardiaque. L'ajustement de ces données par un modèle logistique a confirmé la liaison de ces variables avec la condition cardiaque avec un AUC de 0,81.